



Relatório de Resultados

TÓPICOS EM INTELIGÊNCIA ARTIFICIAL II

Universidade Federal Fluminense

Camila Ferreira

1. Datasets Escolhidos:

Dataset 1:

Estimation of Obesity Levels Dataset

Fonte: [UCI Machine Learning Repository - Dataset 544](#)

Descrição

Este dataset foi criado com o objetivo de prever os níveis de obesidade com base em hábitos alimentares e condições físicas dos indivíduos. Ele foi coletado por meio de questionários preenchidos por pessoas no México, Peru e Colômbia. A base contém variáveis relacionadas a estilo de vida, como frequência de exercícios, consumo de alimentos e histórico de peso.

Informações do Dataset

- **Tamanho:** 2111 instâncias
- **Atributos:** 17 atributos

Atributo Alvo (Target)

- NObeyesdad: Nível de obesidade do indivíduo
 - Normal_Weight
 - Overweight_Level_I
 - Overweight_Level_II
 - Obesity_Type_I
 - Insufficient_Weight
 - Obesity_Type_II
 - Obesity_Type_III

Atributo	Tipo	Descrição
Gender	Categórica	Gênero do indivíduo
Age	Numérica	Idade
Height	Numérica	Altura em metros
Weight	Numérica	Peso em kg
family_history_with_overweight	Booleana	Histórico familiar de sobrepeso
FAVC	Booleana	Consome alimentos calóricos com frequência?
FCVC	Numérica	Frequência de consumo de vegetais
NCP	Numérica	Número de refeições principais por dia
CAEC	Categórica	Consumo de alimentos entre as refeições
SMOKE	Booleana	Fuma

Atributo	Tipo	Descrição
CH2O	Numérica	Consumo diário de água (litros)
SCC	Booleana	Monitora ingestão calórica?
FAF	Numérica	Frequência de atividade física (horas por semana)
TUE	Numérica	Tempo usando tecnologia por dia (horas)
CALC	Categórica	Frequência de consumo de álcool
MTRANS	Categórica	Meio de transporte mais utilizado

Dataset 2:

Contraceptive Method Choice Dataset

Fonte: [UCI Machine Learning Repository - Dataset 30](#)

Descrição

Este dataset foi desenvolvido com o objetivo de prever o método contraceptivo utilizado por mulheres com base em informações socioeconômicas e demográficas. A base é derivada de um estudo realizado na Indonésia e é composta por dados coletados de mulheres casadas que participavam do programa nacional de planejamento familiar. O foco principal é auxiliar na análise de padrões que influenciam a escolha de métodos contraceptivos.

Informações do Dataset

- **Tamanho:** 1473 instâncias
- **Atributos:** 9 atributos

Atributo Alvo (Target)

- **Contraceptive Method Used:** Método contraceptivo utilizado pela mulher
 - 1: Nenhum
 - 2: Curto prazo (pílulas, preservativos, etc.)
 - 3: Longo prazo (DIU, esterilização, etc.)

Atributo	Tipo	Descrição
Wife_age	Numérica	Idade da esposa (em anos)
Wife_education	Categórica	Grau de escolaridade da esposa (1=baixo, 4=alto)
Husband_education	Categórica	Grau de escolaridade do marido (1=baixo, 4=alto)
Num_children	Numérica	Número de filhos vivos
Wife_religion	Booleana	Religião da esposa (0=Islâmica, 1=Outra)

Atributo	Tipo	Descrição
Wife_working	Booleana	A esposa trabalha? (0=Não, 1=Sim)
Husband_occupation	Categórica	Ocupação do marido (valores de 1 a 4)
Standard_of_living	Categórica	Nível de vida (1=baixo, 4=alto)
Media_exposure	Booleana	Exposição à mídia (0=Não exposta, 1=Exposta)

Dataset 3:

Heart Disease Dataset

Fonte: [UCI Machine Learning Repository - Dataset 45](#)

Descrição

Este dataset foi criado com o objetivo de prever a presença de doenças cardíacas em pacientes com base em diversas características clínicas e demográficas. A base contém dados coletados de quatro bancos hospitalares diferentes, sendo a versão mais utilizada aquela que consolida as informações em um único conjunto limpo e padronizado. Os atributos incluem variáveis como idade, sexo, pressão arterial, nível de colesterol e resultados de exames cardíacos.

Informações do Dataset

- **Tamanho:** 303 instâncias (na versão Cleveland, a mais usada)
- **Atributos:** 13 atributos

Atributo Alvo (Target)

- **Grau de doença cardíaca presente no indivíduo :** valores de 0 a 4, onde 0 significa ausência da doença

Atributo	Tipo	Descrição
age	Numérica	Idade do paciente
sex	Binária	Sexo (1 = masculino; 0 = feminino)
cp	Categórica	Tipo de dor no peito (0 a 3)
trestbps	Numérica	Pressão arterial em repouso (mm Hg)
chol	Numérica	Nível sérico de colesterol (mg/dl)
fbs	Binária	Glicemia em jejum > 120 mg/dl (1 = verdadeiro; 0 = falso)
restecg	Categórica	Resultados do eletrocardiograma em repouso
thalach	Numérica	Frequência cardíaca máxima atingida
exang	Binária	Angina induzida por exercício (1 = sim; 0 = não)

Atributo	Tipo	Descrição
oldpeak	Numérica	Depressão do segmento ST induzida por exercício em relação ao repouso
slope	Categórica	Inclinação do segmento ST no esforço máximo
ca	Numérica	Número de vasos principais coloridos por fluoroscopia (0 a 3)
thal	Categórica	Resultado do teste de tálio (3 = normal; 6 = defeito fixo; 7 = reversível)

Dataset 4:

Letter Recognition Dataset

Fonte: [UCI Machine Learning Repository - Dataset 59](#)

Descrição

Este dataset foi criado com o objetivo de classificar letras do alfabeto inglês maiúsculas com base em diversas características extraídas de imagens. Os dados foram gerados a partir de imagens de letras capturadas e processadas para extrair atributos relacionados à geometria e distribuição de pixels. O conjunto de dados é frequentemente usado em estudos de reconhecimento óptico de caracteres (OCR) e aprendizado supervisionado.

Informações do Dataset

- **Tamanho:** 20.000 instâncias
- **Atributos:** 16 atributos preditivos + 1 alvo (letra)

Atributo Alvo (Target)

- Letra do alfabeto (A a Z)
 - Cada instância é rotulada com uma letra maiúscula de 'A' até 'Z'

Atributo	Tipo	Descrição
lettr	Categórica	Letra correspondente à instância (A a Z)
x-box	Numérica	Posição horizontal da caixa delimitadora da letra
y-box	Numérica	Posição vertical da caixa delimitadora da letra
width	Numérica	Largura da caixa delimitadora
high	Numérica	Altura da caixa delimitadora
onpix	Numérica	Número de pixels dentro da caixa
x-bar	Numérica	Centro de massa horizontal
y-bar	Numérica	Centro de massa vertical
x2bar	Numérica	Variância horizontal

Atributo	Tipo	Descrição
y2bar	Numérica	Variância vertical
xybar	Numérica	Correlação entre x e y
x2ybr	Numérica	Correlação de segunda ordem x*y
xy2br	Numérica	Correlação de segunda ordem y*x
x-ege	Numérica	Entropia do perfil horizontal
xegvy	Numérica	Entropia da variância horizontal
y-ege	Numérica	Entropia do perfil vertical
yegvx	Numérica	Entropia da variância vertical

Dataset 5:

Dermatology Dataset

Fonte: [UCI Machine Learning Repository - Dataset 33](#)

Descrição

Este dataset foi criado com o objetivo de auxiliar no diagnóstico de doenças de pele eritemato-esquamosas, que apresentam sintomas semelhantes como eritema (vermelhidão) e descamação, tornando o diagnóstico diferencial um desafio clínico. O conjunto de dados combina informações clínicas e histopatológicas (obtidas por biópsias) para classificar seis tipos diferentes de doenças dermatológicas.

Informações do Dataset

- **Tamanho:** 366 instâncias
- **Atributos:** 34 atributos

Atributo Alvo (Target)

- **class:** Tipo de doença dermatológica
 - 1 – Psoríase (*psoriasis*)
 - 2 – Dermatite seborreica (*seborreic dermatitis*)
 - 3 – Líquen plano (*lichen planus*)
 - 4 – Pitiríase rosada (*pityriasis rosea*)
 - 5 – Dermatite crônica (*chronic dermatitis*)
 - 6 – Pitiríase rubra pilar (*pityriasis rubra pilaris*)

Atributo	Tipo	Descrição
erythema	Numérica	Grau de eritema (0 a 3)
scaling	Numérica	Grau de descamação (0 a 3)
definite_borders	Numérica	Presença de bordas definidas (0 a 3)

Atributo	Tipo	Descrição
itching	Numérica	Grau de coceira (0 a 3)
koebner_phenomenon	Numérica	Fenômeno de Koebner (0 a 3)
polygonal_papules	Numérica	Pápulas poligonais (0 a 3)
follicular_papules	Numérica	Pápulas foliculares (0 a 3)
oral_mucosal_involvement	Numérica	Envolvimento da mucosa oral (0 a 3)
knee_and_elbow_involvement	Numérica	Envolvimento de joelhos/cotovelos (0 a 3)
scalp_involvement	Numérica	Envolvimento do couro cabeludo (0 a 3)
family_history	Booleana	Histórico familiar de doença (0 = não, 1 = sim)
melanin_incontinence	Numérica	Incontinência de melanina (0 a 3)
eosinophils_infiltrate	Numérica	Presença de eosinófilos no infiltrado (0 a 3)
PNL_infiltrate	Numérica	Presença de polimorfonucleares no infiltrado (0 a 3)
fibrosis_of_papillary_dermis	Numérica	Fibrose da derme papilar (0 a 3)
exocytosis	Numérica	Grau de exocitose (0 a 3)
acanthosis	Numérica	Grau de acantose (0 a 3)
hyperkeratosis	Numérica	Grau de hiperqueratose (0 a 3)
parakeratosis	Numérica	Grau de paraqueratose (0 a 3)
clubbing_of_rete_ridges	Numérica	Deformação das cristas da epiderme (0 a 3)
elongation_of_rete_ridges	Numérica	El alongamento das cristas da epiderme (0 a 3)
thinning_of_suprapapillary_epidermis	Numérica	Afinamento da epiderme suprapapilar (0 a 3)
spongiform_pustule	Numérica	Presença de pústula espongiforme (0 a 3)
munro_microabcess	Numérica	Presença de microabscesso de Munro (0 a 3)
focal_hypergranulosis	Numérica	Hipergranulose focal (0 a 3)
disappearance_granular_layer	Numérica	Desaparecimento da camada granulosa (0 a 3)
vacuolisation_basal_layer	Numérica	Vacuolização/dano na camada basal (0 a 3)
spongiosis	Numérica	Grau de espongiose (0 a 3)
saw_tooth_retes	Numérica	Cristas epidérmicas em forma de dente de serra (0 a 3)
follicular_horn_plug	Numérica	Plugue córneo folicular (0 a 3)
perifollicular_parakeratosis	Numérica	Paraqueratose perifolicular (0 a 3)

Atributo	Tipo	Descrição
inflammatory_mononuclear_infiltrate	Numérica	Infiltrado inflamatório mononuclear (0 a 3)
band_like_infiltrate	Numérica	Infiltrado em faixa (0 a 3)
age	Numérica	Idade do paciente

2. Tratamento de Dados

Para os experimentos com Hyperdimensional Computing (HDC), foram utilizadas duas abordagens de codificação distintas: **Record-based** e **N-gram-based**. Ambas as abordagens foram implementadas utilizando a biblioteca **TorchHD**, com vetores hiperdimensionais binários do tipo **BSCTensor**.

2.1 Arquitetura do sistema HDC

A implementação foi dividida em dois módulos principais:

- **Codificadores (Encoders):** Responsáveis por transformar os dados de entrada em vetores hiperdimensionais binários.
- **Modelos HDC (como BinHD ou NeuralHD):** Responsáveis pelo armazenamento e inferência dos padrões aprendidos a partir dos vetores gerados.

2.2 Codificações hiperdimensionais utilizadas

Foram desenvolvidos dois encoders especializados para representar os dados de forma compatível com HDC:

- **Record-based Encoding:** Cada atributo numérico é codificado independentemente com uma combinação entre posição e valor.
 - A posição foi representada com vetores aleatórios utilizando a classe `embeddings.Random`.
 - O valor do atributo foi mapeado em níveis discretos com o encoder `ScatterCode`, baseado na função `bin_level()`, que garante que os vetores associados aos níveis sejam progressivamente diferentes.
 - A codificação final é gerada por meio da operação de *binding* entre posição e valor, seguida por uma agregação (*multiset*) de todos os atributos do registro.
- **N-gram-based Encoding:** Os atributos são combinados sequencialmente simulando uma estrutura de n-grama.
 - Os valores normalizados dos atributos passam pelo mesmo encoder `ScatterCode`, e a combinação é realizada usando a operação de *binding sequence* ou *bundle sequence*, permitindo representar correlações e ordem entre os atributos.

3. Modelo (NeuralHD)

O modelo **NeuralHD** foi implementado com base no paradigma de **Computação Hiperdimensional**, utilizando vetores binários de alta dimensionalidade para representar informações e realizar classificações. A arquitetura utiliza a estrutura de centroids (*Centroid*), mantendo vetores de protótipo para cada classe.

A classe *NeuralHD* é implementada em PyTorch como uma subclasse de *nn.Module*, e realiza um treinamento iterativo com atualização adaptativa dos vetores de classe, incorporando um mecanismo de regeneração de dimensões de baixa variação ao longo das épocas.

3.1. Otimização de Hiperparâmetros

A seleção dos hiperparâmetros do NeuralHD foi realizada por meio da função *grid_search_encoded*, que avalia diferentes combinações de parâmetros sobre os dados já codificados em vetores hiperdimensionais.

O espaço de busca incluiu os seguintes hiperparâmetros:

- **dimension**: tamanho dos vetores hiperdimensionais (por exemplo, 10.000, 20.000, 50.000).
- **num_levels**: número de níveis discretos usados na codificação.
- **regen_rate**: proporção das dimensões a serem regeneradas a cada ciclo.
- **regen_freq**: frequência (em épocas) com que a regeneração é aplicada.
- **epochs**: número total de épocas de treinamento.
- **lr**: taxa de aprendizado utilizada na adaptação dos vetores de classe.

A abordagem adotada no NeuralHD combina a robustez da computação hiperdimensional com mecanismos de adaptação e regeneração inspirados em redes neurais. Sua implementação permite comparar diretamente os impactos de diferentes formas de codificação (Record-based vs. N-gram-based), aproveitando a eficiência vetorial e a baixa complexidade dos classificadores HDC.

3.2 Avaliação do Modelo

O melhor modelo identificado pela busca aleatória é avaliado nos conjuntos de treino e teste. As principais métricas utilizadas são:

- **Acurácia** global
- **Relatório de classificação** com precisão, recall e F1-score por classe
- **Matriz de confusão**, visualizada com *seaborn*

A matriz de confusão permite identificar padrões de erro entre classes reais e previstas, sendo útil especialmente em problemas multiclasse.

Exemplo de geração das métricas:

```
from sklearn.metrics import classification_report, confusion_matrix

print(classification_report(y_test, y_pred, target_names=target_names))

sns.heatmap(confusion_matrix(y_test, y_pred),
```

```
annot=True, fmt='d', cmap='Blues',  
xticklabels=target_names, yticklabels=target_names)
```

3.4 Balanceamento de Classes com SMOTE

Durante a análise dos dados, foi identificado que o *Dataset 2*, o *Dataset 3* e o *Dataset 5* apresentava um desbalanceamento significativo entre as classes da variável alvo. Para resolver esse problema, utilizamos o *SMOTE* (Synthetic Minority Over-sampling Technique, uma técnica de oversampling que cria novas instâncias sintéticas da(s) classe(s) minoritária(s).

Etapas Realizadas no SMOTE

1. Limpeza dos dados:

- Remoção de instâncias com valores ausentes utilizando `.dropna()`.

2. Separação da variável alvo (y) correspondente às instâncias válidas.

3. Aplicação do SMOTE:

- Utilizado com `random_state=42` para reprodutibilidade.
- Gerou amostras sintéticas para balancear as classes.

```
from imblearn.over_sampling import SMOTE  
  
X_cleaned_df = X_processed_df.dropna()  
y_cleaned = y[X_processed_df.notna().all(axis=1)]  
  
smote = SMOTE(random_state=42)  
X_resampled, y_resampled = smote.fit_resample(X_cleaned_df, y_cleaned)
```


4. Resultados:

Dataset 1:

Record encoding

1. **Acurácia no treinamento** : 0.9383886255924171


2. Matriz Confusão dos Testes :



Ngram encoding

1. Acurácia no treinamento : 0.33716993906567366

2. Matriz Confusão dos Testes :




Dataset 2:

Record encoding

1. Acurácia no treinamento : 0.4492424242424242


2. Matriz Confusão dos Testes :



Ngram encoding

1. Acurácia no treinamento : 0.4090909090909091

2. Matriz Confusão dos Testes :




	precision	recall	f1-score	support
1	0.41	0.34	0.37	189
2	0.48	0.15	0.23	189
3	0.36	0.68	0.47	189
accuracy			0.39	567
macro avg	0.42	0.39	0.36	567
weighted avg	0.42	0.39	0.36	567

Dataset 3:

Record encoding

1. Acurácia no treinamento : 0.5446428571428571


2. Matriz Confusão dos Testes :



Ngram encoding

1. Acurácia no treinamento : 0.40535714285714286

2. Matriz Confusão dos Testes :




Dataset 4:

Record encoding

1. Acurácia no treinamento : 0.24221428571428572

2. Matriz Confusão dos Testes :

Acurácia final no teste: 0.10733333333333334




	precision	recall	f1-score	support
A	0.70	0.16	0.27	237
B	0.10	0.01	0.02	230
C	0.25	0.00	0.01	221
D	0.04	0.00	0.01	242
E	0.00	0.00	0.00	230
F	0.14	0.12	0.13	232
G	0.06	0.02	0.03	232
H	0.00	0.00	0.00	220
I	0.83	0.62	0.71	226
J	0.51	0.15	0.23	224
K	0.04	0.28	0.07	222
L	0.36	0.34	0.35	228
M	0.27	0.02	0.03	238
N	0.75	0.01	0.03	235
O	0.04	0.19	0.06	226
P	0.06	0.05	0.05	241
Q	0.05	0.37	0.09	235
R	0.00	0.00	0.00	227
S	0.16	0.02	0.04	224
T	0.67	0.12	0.20	239
U	0.00	0.00	0.00	244
V	0.14	0.29	0.19	229
W	0.28	0.04	0.06	226
X	0.00	0.00	0.00	236
Y	0.00	0.00	0.00	236
Z	0.00	0.00	0.00	220
accuracy			0.11	6000
macro avg	0.21	0.11	0.10	6000
weighted avg	0.21	0.11	0.10	6000

Ngram encoding

1. **Acurácia no treinamento** : 0.06471428571428571

2. Matriz Confusão dos Testes :

Acurácia final no teste: 0.06466666666666666



	precision	recall	f1-score	support
A	0.00	0.00	0.00	237
B	0.00	0.00	0.00	230
C	0.00	0.00	0.00	221
D	0.00	0.00	0.00	242
E	0.00	0.00	0.00	230
F	0.00	0.00	0.00	232
G	0.00	0.00	0.00	232
H	0.00	0.00	0.00	220
I	0.87	0.32	0.47	226
J	0.23	0.22	0.22	224
K	0.00	0.00	0.00	222
L	0.00	0.00	0.00	228
M	0.00	0.00	0.00	238
N	0.00	0.00	0.00	235
O	0.00	0.00	0.00	226
P	0.00	0.00	0.00	241
Q	0.00	0.00	0.00	235
R	0.00	0.00	0.00	227
S	0.04	0.79	0.07	224
T	0.40	0.14	0.20	239
U	0.00	0.00	0.00	244
V	0.07	0.25	0.11	229
W	0.00	0.00	0.00	226
X	0.00	0.00	0.00	236
Y	0.00	0.00	0.00	236
Z	0.00	0.00	0.00	220
accuracy			0.06	6000
macro avg	0.06	0.07	0.04	6000
weighted avg	0.06	0.06	0.04	6000

5 Análise Comparativa: Record-based vs. N-gram-based

5.1 Resultados por Dataset

Dataset 1 — *Estimation of Obesity Levels*

Codificação	Acurácia Treino
Record-based	0.938
N-gram-based	0.337

Dataset 2 — *Contraceptive Method Choice*

Codificação	Acurácia Treino
Record-based	0.449

Codificação	Acurácia Treino
N-gram-based	0.409

Dataset 3 — *Heart Disease*

Codificação	Acurácia Treino
Record-based	0.544
N-gram-based	0.405

Dataset 4 — *Letter Recognition*

Codificação	Acurácia Treino
Record-based	0.242
N-gram-based	0.064

Dataset 5 — *Dermatology*

Codificação	Acurácia Treino
Record-based	1.000 (overfitting)
N-gram-based	0.453

Média Geral das Acurácias de Treinamento

Codificação	Média Acurácia
Record-based	0.634
N-gram-based	0.334

5.2 Conclusões

- **Record-based** apresentou **melhor desempenho em todos os datasets**, sendo mais robusto e confiável para dados tabulares com atributos independentes.
- **N-gram-based** ainda é promissor para casos com **correlações e sequências relevantes**, mas mostrou limitações práticas nesta análise.
- O **overfitting observado no Dataset 5** com Record-based ressalta a importância de validação cruzada e generalização.